

---

---

---


---

---



## Perceptron (단층)

- 비선형 표현 불가. (복잡한 함수 표현 불가) (의미있는 값을 얻지 못함)
- w, b를 직접 손으로 정해줘야 함.
- activation function을 step function



$x_1$ : 입력  
 $y$ : 출력  
 $w$ : 가중치 (신호의 영향력 제어)  
 $b$ : 편향 (누런, 노드와 얼마나 쉽게 활성화되나)


$$y = \begin{cases} 1 & (x_1 \cdot w_1 + x_2 \cdot w_2 + b > 0) \\ 0 & (x_1 \cdot w_1 + x_2 \cdot w_2 + b \leq 0) \end{cases}$$



$$y = h(x_1 \cdot w_1 + x_2 \cdot w_2 + b)$$

$$h(x) = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

입력 신호의 총합을 출력 신호로 변환하는 함수  
= 활성화 함수  
= activation function



$$h(x) = x$$



$$h(x) = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

$$h(x) = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

$$h(x) = \frac{1}{1 + e^{-x}}$$

$$y_k = \frac{e^{(a_k)}}{\sum_{i=1}^n e^{(a_i)}} \quad n = \text{출력층의 node 개수}$$

$y_k = \text{그중 } k\text{번째 출력}$



- 여러 회귀 문제
- 선형 함수 (직선)
- 비선형 (한 가지 직선을 그을 수 없음)
- 0, 1 만 출력
- hidden layer

- 이진 분류 문제
- 'S자 모양' 이란 뜻
- 비선형
- 연속값 (0, 0.284, 0.47, 1)


- 다중 분류 문제
- 총합 1로써, 전체 확률 1 보임

$$e(x)$$

## 다층 퍼셉트론 신경망

- multi layer perceptron으로 복잡한 함수 표현 가능
- 여러가지 activation function 사용 (비선형 표현 가능) (복잡한 의미 가능)

'2층 신경망'  
(가중치 층 2개까)

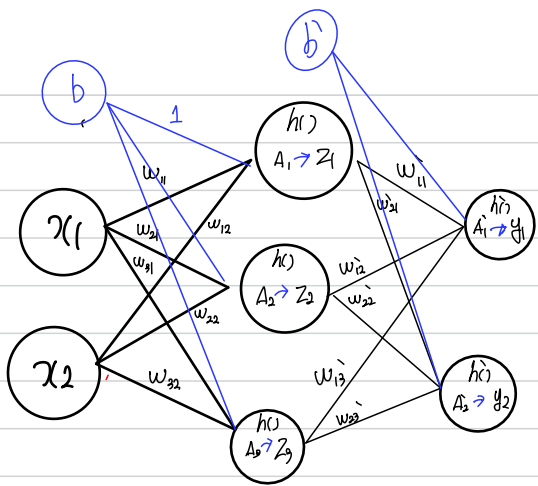


입력층 input layer    은닉층 hidden layer    출력층 output layer

$$y_1 \cdot w_{11} + y_1 \cdot w_{12}$$

- 1) why activation function을 선형이 아닌 비선형으로 해야 하나?  $\Rightarrow$  층을 쌓는 의미가 없어진다.
- 2) 풀고 싶은 골라가기.

과연 레이어 데이터 = 열 vector (abc)  
가려짐 = 컬럼 vector (b)



(for에 T 필요, back에 T 불필요)

$W_{ij}$

$$\begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ z_3 \end{pmatrix}$$

3x2      2x1

(for에 T 불필요, back에 필요)

$W_{ji}$

$$\begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ z_3 \end{pmatrix}$$

2x3      (3x1)

$$\begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{pmatrix} + \begin{pmatrix} b_1 & b_2 & b_3 \end{pmatrix} = \begin{pmatrix} z_1 \\ z_2 \\ z_3 \end{pmatrix}$$

1x2      2x3      1x3      3x1

$$XW + B = A$$

$h(A) = Z$        $W' + b' = A'$

$Z = WX + b$  (Wji 포함)  
 $h(A) = y$

relu (Rectified Linear Unit, 경사 함수)

$h = \max(0, x)$



- $h' = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$  Vanishing Gradient Problem solve!!
- easy! 연산 비용이 적고. 구현이 매우 간단
- 0 이하보다 작으면 죽는다.

## Sigmoid

$$h = \frac{1}{1 + e^{-x}}$$

$$h' = \frac{0 \cdot (1 + e^{-x}) - 1 \cdot (-e^{-x})}{(1 + e^{-x})^2}$$

$$= \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$= \frac{1 + e^{-x}}{(1 + e^{-x})^2} - \frac{1}{(1 + e^{-x})^2}$$

$$= \frac{1}{1 + e^{-x}} - \frac{1}{(1 + e^{-x})^2}$$

$$= \frac{1}{1 + e^{-x}} \left( 1 - \frac{1}{1 + e^{-x}} \right)$$

$$= h(1 - h)$$

odds(P) =  $\frac{P}{1-P}$

$\lg(odds(P)) = wx + b$

$e^{wx+b} = odds(P)$

$odds(P) = \frac{P}{1-P}$

$(1-P)e^{wx+b} = P$


$e^{wx+b} - P e^{wx+b} - P = 0$

$P(1 + e^{wx+b}) = e^{wx+b}$

$P = \frac{e^{wx+b}}{1 + e^{wx+b}}$

$P = \frac{1}{1 + e^{-\frac{wx+b}{P}}}$   $\frac{1}{1 + e^{-\frac{1}{P}(wx+b)}}$

node 1개



확률  $0 < P < 1$

$0 < odds(P) < \infty$

$-\infty < \lg(odds(P)) < \infty$


출력층이 이진 선형 회귀 문제의 의미 있음

$= wx + b$


## Softmax

$h_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$

1: 출력층 node 갯수  
k: 출력층 node의 k번째



- 지수함수에게 w가 다 제네 효과
- 각 node 값의 곱에 1에 가까워지면 확률 1
- 단조 증가 함수에게 대수 관계는 그대로임!



$x \cdot w + b = Z = (z_1, z_2, z_3)$

$$\text{Softmax}(Z) = \left( \frac{e^{z_1}}{\sum_{i=1}^3 e^{z_i}}, \frac{e^{z_2}}{\sum_{i=1}^3 e^{z_i}}, \frac{e^{z_3}}{\sum_{i=1}^3 e^{z_i}} \right)$$

$$= (P(a), P(b), P(c)) \quad (P(a) + P(b) + P(c) = 1)$$

$$= (0.1, 0.2, 0.1)$$

(참고)

- $(-\infty, \infty)$  값을  $(0, 1)$ 로 표현 가능  $\rightarrow$  확률 표현 가능
- Sigmoid 층을 여러 번 쓴다면 기울기의 최대값이 0.25 이므로 지나갈 때 마다 매번 값이 작아짐  $\rightarrow$  그 차이를 계산하기 어려움

Binary classification에서 0.5 기준으로 삼으면 a. 안습면, 3 개 가능.

$\Rightarrow$  Vanishing Gradient Problem (작아지거나 0이 되면 안됨) step function

↳ 4층에 back Propagation에서 문제적



# Leaky ReLU

# Tanh

$$h = \max(0, x, x)$$

$$h = \frac{1 - e^{-x}}{1 + e^x}$$

$$h' = (1 - \tanh(x))(1 + \tanh(x))$$



o Relu의 문제점 해결  
( $x < 0$  는 기울기 0이 되어  
뉴런 노드가 죽는 현상)

o 기울기의 최대값이 1로 고정되었지만  
다른 가중치로 낮은 값들로 인해 층을 지날수록  
Vanishing gradient Problem 발생

o 수치형 자료 → 연속형 자료 ex) 키, 몸무게  
이산형 자료 ex) abs(키, 몸무게), 교통사고 건수(16회)


o 범형 자료 → 순위형 자료 순서대로 나열 ex) 학점(A=2, B=4, C=6...)  
명목형 자료 ex) 성별(남=1, 여=2), 종교(기독교=1, 불교=2, 천주교=3)  
ex) 혈액형

How to separate Linear regression and Logistic Regression?

⇒ what is data? (종속변수 y)

if) data is numerical data ⇒ Linear regression  $(-\infty, \infty)$

if) data is categorical data ⇒ Logistic Regression  $(0, 1)$   
false True



토릿 =  $\log + \text{odds}$  의 역지  
(= 실패 비율 대비 성공비율)  
 $0 < P < 1$   
 $0 < \frac{P}{1-P} < \infty$   
 $\rightarrow \log \left( \frac{P}{1-P} \right) < \infty$   
 $\log \left( \frac{P}{1-P} \right) = ax + b$   
 $e^{ax+b} = \frac{P}{1-P}$   
 $P = \frac{1}{1 + e^{-(ax+b)}}$   
P에 대해 역변환.  
Sigmoid function.

∴ 포해서  
이진분류에 사용