
heum



SE net

○ 2017 ILSVRC classification 1위
○ 2018 HM squeeze and excitation networks

○ channel 간의 inter-dependency를 modelling

→ channel-wise feature response를 adaptive 하게 recalibration 해주는 unit을 만들자!

⇒ Squeeze-and-Excitation (SE) block을 제안.

○ SE block을 위한 조금의 cost만 지불해준다면 기존의 Architecture 성별과 크게 향상 효과 기대.

○ CNN에서는 conv layer에 'non-linear activation'과 'downsampling operator'를 사용하는데

- Hierarchical pattern의 capture
- Global theoretical receptive field

위 목적을 달성하는 Powerful image representation을 찾는 것.

Network에서 생성된 representation을 향상시키기 위해

○ Squeeze

— spatial dimension ($H \times W$)에 걸친 feature map을 aggregation 함으로써 channel descriptor를 생성.

— 이 descriptor는 channel-wise feature response의 global distribution을 묘사하며, 네트워크의 모든 layer에서 global field에서 얻을 수 있는 information을 사용할 수 있도록 해준다.

○ Excitation

— 임베딩을 input으로 하여 per-channel modulation weight를 생성하는 Simple self-gating 메커니즘의 형태

— 이 weight 들은 feature map T 에 적용되며, 이렇게 생성된 SE block의 출력은 후속 layer에 바로 사용될 수 있다.

○ 또한 SE block은 다양한 depth의 네트워크 architecture에서 original block의 대체로도 사용 가능
⇒ flexible

in earlier layer

- class에 대해 받지 않는 형식으로 무관한 feature 들을 자극
- shared low-level representation을 강화

in later layer

- 점점 더 specialised 되며
- class에 특화된 방식으로 다른 input에 응답

class2 = image

○ 특정 task나 dataset에 제한되지 않는다고 제시함




Fig. 1 A Squeeze and Excitation block

Squeeze	top-1 err.	top-5 err.
Max	22.57	6.09
Avg	22.28	6.03

Table 11.

Excitation	top-1 err.	top-5 err.
ReLU	23.47	6.98
Tanh	23.00	6.38
Sigmoid	22.28	6.03

Table 12.

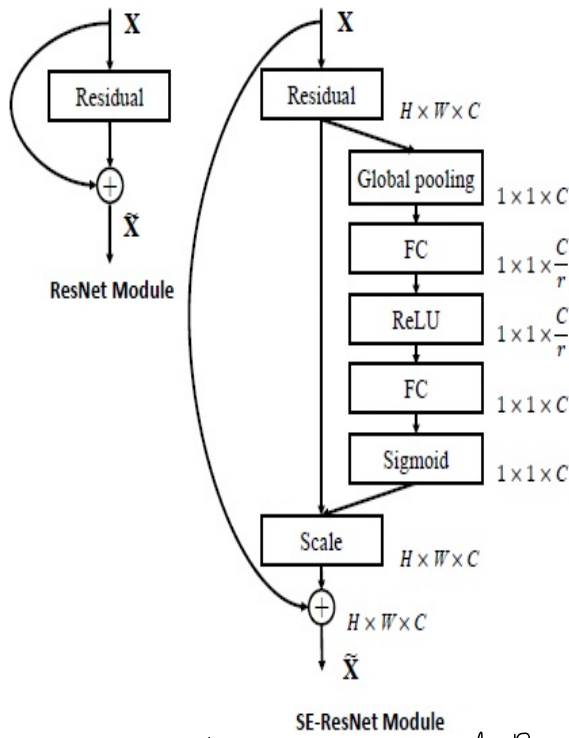


Fig 3. The schema of the original Residual module (left) and the SE-ResNet module (right)

Ratio r	top-1 err.	top-5 err.	Params
2	22.29	6.00	45.7M
4	22.25	6.09	35.7M
8	22.26	5.99	30.7M
16	22.28	6.03	28.1M
32	22.72	6.20	26.9M
original	23.30	6.55	25.6M

Table 10.

final stage (Per.)

- 상대적으로 later layer에 있는 channel이 대부분의 Parameter를 차지함
- final stage, later layer에 SE block을 없을 경우 ~4%의 Parameter 증대로 0.1% 미만의 작은 손실만 개선될 수 있다.

ex) final stage의 channel이 5/2과 같으며 이 stage엔 SE block 사용 안함.
final stage - 1의 SE block만 사용.

Stage	top-1 err.	top-5 err.	GFLOPs	Params
ResNet-50	23.30	6.55	3.86	25.6M
SE_Stage_2	23.03	6.48	3.86	25.6M
SE_Stage_3	23.04	6.32	3.86	25.7M
SE_Stage_4	22.68	6.22	3.86	26.4M
SE (All)	22.28	6.03	3.87	28.1M

Table 13.

Representational Power 네트워크의 표현력

Attention and gating mechanisms

→ Attention은 이용 가능한 computational resource를, signal 중 가장 유익한 요소에 할당하는 성향을 갖게끔 유도할 수 있다.

ex) Sequence learning

ex) localization and understanding in image

ex) Image captioning

ex) Lip reading.

→ 이러한 응용 연구들에선 원본의 개념들 간의 작은 차이

고차원의 abstraction을 나타내는 1개 이상의 layer로 이러한 차이를 효과적으로 잘

SE block에서는 lightweight gating 메커니즘으로

⇒ computationally efficient한 channel-wise relationship을 모델링,

네트워크의 representational power를 향상시키는 것에 중점을 둔.

hyper-parameter

- mini-batch size = 1024

- Initial learning rate = 0.6

- 30 epoch → 0.1 lr

- He initialization (weight initialization)

- Train for 100epoch.

- reduction ratio $\gamma = 16$

SE block 자체가 depth를 추가하는 점

→ 매우 효율적인 계산 방식으로 동작

→ 기본 architecture의 depth가 늘어남에 따라 return이 감소하는 지점에서도 좋은 결과를 얻을 수 있다.

ex) Presnet-50 < SE-presnet-50 < Resnet-101

7.48%


6.62%

6.52%

25M Param

25M + 2.5 Param

10%를 cost 더 주고 100 layer에 비슷한 효과를 낼 수 있다. 참! 카타르치로!



○ How to join SE block?

→ SE-Post block을 제외한 나머지는 비슷한 성능을 보임

Table 5. SE block integration designs explored in the ablation study
(통합 설계)

Design	top-1 err.	top-5 err.
SE	22.28	6.03
SE-PRE	22.23	6.00
SE-POST	22.78	6.35
SE-Identity	22.20	6.15

Table 4. Effect of different SE block integration strategies with ResNet-50 on ImageNet (error rates)

○ 아무래도 ResNet의 Paper에 영향을 받지 않았나.. 라는 생각.

○ SE-PRE block이 조금이라도 더 좋아보인 하는데, 이왕 쓰기 standard SE block 보다 SE-PRE block은 한번 써볼까
(뭐.. 거의 차이가 없긴데..)

(지점 집계) 77
○ branch aggregation 이전에 적용해야 효과가 있다는 사실만 알고 가자.

즉, Squeeze 와 Excitation 이라는 연산작업을 통해 정보의 압축, 재 조정을 효율적으로 가능.
적은 cost (연산량)으로도 성능향상 가능.
flexible (유연) 하게 기존 네트워크 (architecture)에도 사용가능.

궁금증

하위 (low) layer에선 general한 feature를 학습,
상위 (high) layer에서 고차원의 feature를 학습한다 했는데

conv1D에선 어떤 filter로 general과 고차원의 feature를 학습하?
비슷한가?